

Trabalho 1 - Inteligência Artificial II

Previsão de assinatura de depósito a prazo com Random Forest

1. Dataset

Foi utilizada a base Bank Marketing, disponibilizada pelo repositório da University of California Irvine (UCI). Foi utilizada a maior versão do dataset, com 45.211 registros.

Link de acesso: <https://archive.ics.uci.edu/dataset/222/bank+marketing>

A base reúne informações demográficas, financeiras e de contato de clientes abordados em campanhas telefônicas de um banco português. A variável y informa se o cliente assinou ou não um depósito a prazo.

2. Problema e objetivo

O problema é uma classificação binária: cada cliente pertence à classe Assinou ou Não assinou. A aplicação busca apoiar a priorização dos contatos comerciais, indicando quais clientes apresentam maior probabilidade de adesão. O objetivo não é substituir a decisão da equipe de marketing, mas organizar a lista de contatos.

3. Exploração e preparação dos dados

A análise exploratória verifica o formato da base, os tipos das colunas, valores ausentes, duplicidades e a distribuição do alvo. A classe Não assinou é majoritária, enquanto os assinantes representam aproximadamente 11,7% da base. Esse desbalanceamento torna a acurácia isolada pouco informativa.

As duplicidades completas foram verificadas e removidas antes da divisão dos dados. Marcadores de ausência foram tratados como valores ausentes. Variáveis numéricas recebem imputação pela mediana e variáveis categóricas pela categoria mais frequente. As categorias são transformadas por One-Hot Encoding.

A variável duration foi retirada das entradas. Ela registra a duração da ligação e só é conhecida durante ou depois do contato.

4. Estratégia experimental e modelagem

Os dados foram divididos em 80% para treino e 20% para teste, com estratificação da variável alvo e random_state igual a 42. Assim, a proporção de assinantes é mantida nos dois conjuntos.

O pré-processamento e o classificador foram reunidos em um Pipeline. Dessa forma, as transformações são ajustadas no conjunto de treino e aplicadas ao teste sem usar informações do resultado real do teste durante o treinamento.

Parâmetro	Valor	Motivo
n_estimators	200	Quantidade de árvores suficiente para estabilizar a floresta.
criterion	entropy	Critério usado para avaliar a separação das classes.
max_depth	12	Limita a complexidade das árvores.
min_samples_leaf	3	Evita folhas formadas por poucos registros.
max_features	sqrt	Diversifica as árvores ao usar parte das variáveis.

class_weight	balanced	Dá mais peso à classe minoritária Assinou.
--------------	----------	--

5. Avaliação e análise dos resultados

A tabela apresenta os resultados obtidos no treino e no teste. O conjunto de teste foi usado para a avaliação final da versão apresentada.

Conjunto	Acurácia	Precisão	Revocação	F1	AUC-ROC
Treino	84,63%	40,03%	63,03%	48,96%	0,8529
Teste	83,43%	36,78%	57,84%	44,97%	0,7858

O modelo encontrou 612 dos 1.058 assinantes do conjunto de teste, correspondendo a uma revocação de 57,84%. Ao mesmo tempo, indicou 1.664 clientes como possíveis assinantes, dos quais 612 realmente assinaram. Por isso, a precisão foi de 36,78%: aproximadamente 37 em cada 100 clientes indicados assinaram.

A precisão ficou limitada principalmente pelo desbalanceamento da base e pela sobreposição entre os perfis de clientes que assinam e que não assinam. Como o objetivo é encontrar mais assinantes, foi usado `class_weight=balanced`. Essa escolha aumenta a atenção dada à classe minoritária, mas também faz o modelo indicar mais falsos positivos. A retirada de `duration` também reduz o desempenho, mas é necessária para evitar vazamento.




Figura 1 - Matriz de confusão

6. Demonstração de funcionamento

O notebook inclui uma etapa com cinco clientes fictícios. Os perfis variam em idade, profissão, estado civil, educação, saldo, empréstimos, forma de contato e histórico de campanhas. A célula aplica ao mesmo tempo `predict_proba()`, para mostrar a probabilidade estimada, e `predict()`, para apresentar a classe final.

Cliente	Perfil resumido
Cliente 1	28 anos, estudante, solteiro, saldo positivo, sem empréstimos.
Cliente 2	54 anos, management, casado, saldo positivo e contato celular.
Cliente 3	42 anos, blue-collar, saldo negativo e empréstimo pessoal.
Cliente 4	67 anos, aposentado, saldo alto e histórico anterior.
Cliente 5	35 anos, empreendedor, saldo baixo e empréstimos ativos.

Resultado:

	cliente	probabilidadeassinatura	previsao
0	Cliente 1	0.6765	Assinaria
1	Cliente 2	0.9004	Assinaria
2	Cliente 3	0.2126	Nao assinaria
3	Cliente 4	0.7027	Assinaria
4	Cliente 5	0.3219	Nao assinaria

Essa etapa demonstra o uso do modelo em novos registros. As probabilidades são estimativas do classificador e não representam garantia de assinatura.

7. Conclusão e limitações

O Random Forest conseguiu separar parte dos clientes com maior chance de assinatura e encontrou 57,84% dos assinantes no teste. A lista indicada pelo modelo teve uma concentração de assinantes maior que a proporção original da base, o que pode ajudar na priorização dos contatos.

A principal limitação é a precisão de 36,78% para a classe Assinou. Isso significa que ainda há muitos falsos positivos. O resultado poderia ser usado como apoio à priorização, não como decisão definitiva.

8. Referências

UCI Machine Learning Repository. Bank Marketing.
<https://archive.ics.uci.edu/dataset/222/bank+marketing>